

Control de cambios:

Tercera semana – 10 de mayo 2026

- Se realiza confirmación de las características de los campos, para las fechas se realiza ajuste de formato y normalización
- Se realiza clasificación de columnas en categóricas y numéricas para separar las transformaciones requeridas para el modelo
- Se realiza análisis de valores únicos de las columnas categóricas
- Se realiza análisis de valores nulos de la base de datos, encontrando un 22% de nulos.
- Se realiza transformación de los datos nulos a sin información para una posterior limpieza o normalización para el modelo
- Se extrae y relaciona las fuentes de datos externas kev y epss como confirmación de un ataque exitoso.
- Se realiza nuevamente análisis de nulos posterior a la relación con las nuevas fuentes de datos, donde se encuentra solo 0.5% de CVE con resultados.
- Se realiza el calculo de la variable dependiente del modelo (probabilidad de ataque) y clasificación de riesgo de ataque (risk_score)
- Se separan variables que van a entrar al modelo de probabilidad binario y de los que entran al modelo de clasificación
- Se realiza identificación de variables con alta cardinalidad, encontrando 3 variables: vendedor, producto y cpe
- Se construye diccionario de datos para realizar agrupación semántica y relacional para disminuir la cardinalidad de los datos.

Cuarta semana – 17 de mayo 2026

- Se termino de realizar la limpieza y categorización de los datos con alta cardinalidad, con lo cual se obtiene un dataframe de tamaño (325485, 153).
- Se hace un top 50 de vendors y se agrupa los remanentes en unknown_vendor.
- Se realiza 30 agrupaciones de products para reducir significativamente la cardinalidad por el proveedor y por el objetivo del producto.
- Se agrupa CPE por su relación técnica para reducir la cardinalidad.
- Se comienza la búsqueda de modelos predictivos, probando 5 modelos clasificatorios (LightGBM, XGboost, Catboost, RandomForest, GradientBoosting).
- Con las variables iniciales hay un leakage aparente por lo que se realizan pruebas eliminando variables que el usuario no tendría y que hacen que el modelo aprenda los datos (Resultados accuracy promedio: 0.998).

Cuarta semana – 24 de mayo 2026

- Se realizo iteración eliminando variables de leakage y variables ajenas al cliente logrando bajar las métricas a resultados más realistas.

- Se corrió el modelo para 3 variables dependientes diferentes y se encontró que los resultados para “IS_KEV” son muy deficientes, por lo tanto, se elimina como variable del modelo
- Bajo las dos variables restante “RISK_SCORE” y “RISK_TIER” se encontraron buenos resultados para 3 modelos, donde el mejor fue Random forest
- Se obtuvieron métricas iniciales como base de los modelos: Accuracy de 0.78, F1 de 0.78, R2 de 0.70, RMSE de 0.067
- Se contruyo el código para hacer optimización de hiperparametros